


4.2.2 Algoritmul AdaBoost

59.


(Algoritmul AdaBoost: întrebări în legătură cu aplicarea algoritmului pe un set de date din \mathbb{R})

• CMU, 2011 fall, T. Mitchell, A. Singh, HW6, pr. 3.2-8

Considerăm setul de date de antrenament din figura următoare. Simbolurile • și ○ desemnează etichete pozitive și respectiv etichete negative. Vom folosi algoritmul AdaBoost cu compași de decizie în rolul de ipoteze „slabe“.



- Determinați separatorul decizional corespunzător primei ipoteze „slabe“, h_1 . Desenați-l pe figura de mai sus și indicați [eventual printr-o mică săgeată perpendiculară pe acest separator] care este zona clasificată cu +.
- Calculați ε_1 și α_1 . Cât este acuratețea obținută de AdaBoost la antrenare dacă oprim acum algoritmul?
- Cât va fi valoarea noilor probabilități / ponderi $D_2(i)$ pentru fiecare dintre celeșapte exemple de antrenament?
- Identificați în mod riguros separatorul decizional corespunzător celei de-a doua ipoteze „slabe“, h_2 și apoi includeți-l în desen. Indicați iarăși zona de decizie corespunzătoare clasei +.
- Care sunt exemplele de antrenament cărora le va fi asignată cea mai mică pondere / probabilitate după ce algoritmul AdaBoost va fi terminat cea de-a doua sa iteratie?
- Se îmbunătățește oare acuratețea la antrenare obținută de AdaBoost la a doua iteratie în raport cu cea obținută la prima iteratie?



Înțelegem separatoare.

D	$x \approx 0.25$	$x \approx 0.65$	
$err h_1(x < 0)$	$1/7$	$3 \cdot \frac{1}{7} + \frac{1}{7} = \frac{5}{7}$	-1.5
$err h_1(x \geq 0)$	$\frac{6}{7}$	$\frac{2}{7}$	$\frac{3}{7}$

ablegen minimal.

$$\varepsilon_1 = \frac{1}{3}$$


$$h_1(x) = \text{sign}(x < -0.25) = \text{sign}(-0.25 - x)$$

$$f_1 = \frac{1}{2} - \varepsilon_1 = \frac{1}{2} - \frac{1}{3} = \frac{5}{6}$$

$$\alpha_1 = \frac{1}{2} \ln \frac{1-\varepsilon_1}{\varepsilon_1} = \frac{1}{2} \ln \frac{\frac{1}{6}}{\frac{1}{3}} = \ln \sqrt{6}$$

Actualisierung wendelt:

$$\left\{ \begin{array}{l} \frac{D_t(i)}{2 \cdot \varepsilon_t}, \quad i \in \{0, 8\} \quad (\text{good}) \\ \frac{D_t(i)}{2 \cdot (1 - \varepsilon_t)}, \quad i \notin \{0, 8\} \quad (\text{correct}) \end{array} \right.$$



$$-1, -0.7, -0.9: \frac{\frac{1}{6}}{2 \cdot \frac{1}{3}} = \frac{1}{12}$$

$$-0.1, 0.2, 0.5: \frac{\frac{1}{6}}{2 \cdot \frac{1}{3}} = \frac{1}{12}$$


$$0.8: \frac{\frac{1}{6}}{2 \cdot \frac{1}{3}} = \frac{1}{2}$$

Daraus ein empirisch aktualisiertes f_1 :

$$H_1(x) = \text{sign}(2_1 \cdot h_1(x)) = \text{sign}\left(\frac{1}{2} \cdot \text{sign}(-0.25 - x)\right)$$

	target	prediction $H_3(x)$
$X_1 = -1$	+1	+
$X_2 = -0.2$	+1	+
$X_3 = -0.4$	-1	+
$X_4 = -0.1$	-1	-
$X_5 = 0.2$	-1	-
$X_6 = 0.5$	-1	-
$X_7 = 0.8$	+1	-

$$\text{err model} = \frac{1}{7}$$




γ	-0.25	0.65	$\underline{-1.5}$
$\text{err } D_2 (x < \gamma)$	$\frac{1}{2}$	$\frac{1}{2} + \frac{3}{12} \cdot \frac{1}{12} = \frac{3}{4}$	$\underline{\frac{3}{12} + \frac{1}{2} = \frac{9}{12} = \frac{3}{4}}$
$\text{err } D_2 (x \geq \gamma)$	$\frac{1}{2}$	$\frac{1}{4}$	$\underline{\frac{1}{4}}$

$$\varepsilon_2 = \frac{1}{4}$$

$$h_2 = (x \geq 0.65) = (x - 0.65) \geq 0$$

$$\alpha_2 = \frac{1}{2} \ln \frac{\frac{1}{4}}{\frac{1}{9}} = \ln \sqrt{3}$$

$$\left\{ \begin{array}{l} \frac{D_2(i)}{2 \cdot \epsilon_2}, \quad i \in \{-1, -0.2, -0.4\} \text{ (grazite)} \\ \frac{D_2(i)}{2 \cdot (1-\epsilon_2)}, \quad i \notin \{-1, -0.2, -0.4\} \text{ (correct)} \end{array} \right.$$



e) Examples where f_i can be assigned correctly, even

at $\beta = 0$ $i = -0.1, 0.2, 0.5$ with probabilities $\frac{1}{18}$

$$\ln \sqrt{6} > \ln \sqrt{3}$$

f) ~~Der reine Informationsgehalt: $H_2(f_i) = \text{negm}(d_1 \text{negm}(-0.25-x) + d_2 \text{negm}(x-0.5))$~~

i	Δ_t	D_1^i	D_2^i	D_3^i	D_4^i	D_5^i	D_6^i	D_7^i
1	$\ln \sqrt{6}$	+	+	+	-	-	-	-
2	$\ln \sqrt{3}$	-	-	-	-	-	-	+
$H_T(x_i)$		+	+	+	-	-	=	-

Aparent acuratețea + cel nu s-a implementat în
este la fel.

60.

(AdaBoost: aplicare pe un set de date din \mathbb{R}^2)

adaptare facută de Liviu Ciortuz, după


• o MIT, 2004 fall, Tommi Jaakkola, final, pr. 1

Fie setul de exemple de antrenament (instanțe etichetate) din figura de mai jos. Simbolurile \bullet și \circ desemnează etichete pozitive și respectiv etichete negative. Pentru a rezolva această problemă de clasificare, vă cerem să aplicați algoritmul AdaBoost folosind drept ipoteze „slabe“ compași de decizie (engl., decision stump). La fiecare iterație de boosting veți selecta acel compas de decizie care minimizează eroarea ponderată la antrenare (engl., weighted training error). În cazul în care există mai mulți compași de decizie care au [o


597

aceeași] cea mai bună eroare ponderată la antrenare, veți putea alege unul dintre ei în mod arbitrar.

- Pe figura dată, desenați primul compas de decizie și etichetați-l cu h_1 , indicând de asemenea cu $+$ / $-$ cele două zone de decizie pe care le determină acest compas.
 - Pe aceeași figură, scrieți în apropierea fiecărei instanțe probabilitatea asignată ei după prima iterare executată de algoritmul AdaBoost. De asemenea, încercuiți instanțele care au probabilitatea cea mai mare. Justificați răspunsul în mod riguros.
 - Cât este eroarea ponderată la antrenare produsă de primul compas de decizie după prima iterare, adică după ce probabilitățile asociate instanțelor au fost recalculate? Justificați.
 - Desenați pe figura dată cel de-al doilea compas de decizie și etichetați-l cu h_2 , indicând de asemenea cu $+$ / $-$ cele două zone de decizie pe care le determină acest compas.
 - Există oare instanțe de antrenament care sunt clasificate eronat de către H_2 , ipoteza combinată produsă de AdaBoost după două iterări? Justificați răspunsul în mod riguros.
 - Dacă răspunsul pe care l-ați dat la punctul e este pozitiv, ce se poate spune dacă se execută încă o iterare (adică, a treia)? Desenați pe figura dată cel de-al treilea compas de decizie și etichetați-l cu h_3 , indicând de asemenea cu $+$ / $-$ cele două zone de decizie pe care le determină acest compas. Dacă eroarea la antrenare este acum 0, trasați separatorul decizional determinat de algoritmul AdaBoost.
- Care ar fi rezultatul dacă AdaBoost ar alege ca a treia ipoteză „slabă“ un alt (cel mai bun!) compas de decizie (h'_3) în locul lui h_3 ?



0)



X_2 :	0	0.25	1	1.75	2.5	3.5
$\text{err } D_1(X_2 \geq 0)$	$\frac{5}{9}$	$6/9$	$5/9$	$6/9$	$5/9$	
$\text{err } D_1(X_2 \geq 1)$	$\frac{4}{9}$	$3/9$	$4/9$	$3/9$	$4/9$	

X_1 :	0	0.5	2.5	3.5	4.5
$\text{err } D_1(X_1 \geq 0)$	$5/9$	$8/9$	$6/9$	$7/9$	
$\text{err } D_1(X_1 \geq 1)$	$4/9$	$1/9$	$3/9$	$2/9$	

$$\epsilon_1 = \frac{1}{9} \quad h_1 = (X_1 \geq 2.5) = (X_1 - 2.5 \geq 0)$$


$$d_1 = \frac{1}{2} \ln \left(\frac{8}{\frac{1}{9}} \right) = \ln \sqrt{8}$$

X_i	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
$D_2(X_i)$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{2}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$


$$\begin{cases} \frac{D_1(i)}{2 \cdot \epsilon_1}, & i \in \{G\} \\ \frac{D_1(i)}{2 \cdot (1 - \epsilon_1)}, & i \notin \{G\} \end{cases}$$

$$x_6: \frac{\frac{1}{9}}{2 \cdot \frac{1}{9}} = \frac{1}{2}$$

$$x_{\{1, 2, \dots, 9\} - \{G\}}: \frac{\frac{1}{9}}{2 \cdot \frac{8}{9}} = \frac{1}{16}$$



c) vă văd. că antrenarea este de $\frac{1}{9}$, decare de la x_6
șă fie clasificat gresit.



$X_1:$	0.5	2.5	3.5	4.5
$\text{err}_D_2(X_1 < 5)$	$5/16$	$8/16$	$6/16$	$\frac{6}{16} + \frac{1}{2} = \frac{15}{16}$
$\text{err}_D_2(X_1 \geq 5)$	$11/16$	$8/16$	$10/16$	$2/16$

$X_2:$	0	0.25	1	1.75	2.5	3.5
$\text{err}_D_2(X_2 < 1)$	$5/16$	$\frac{5}{16} + \frac{1}{2} = \frac{13}{16}$	$\frac{12}{16}$	$\frac{13}{16}$	$\frac{12}{16}$	
$\text{err}_D_2(X_2 \geq 1)$	$11/16$	$\frac{3}{16}$	$\frac{9}{16}$	$\frac{3}{16}$	$\frac{9}{16}$	


$$\varepsilon_2 = \frac{2}{16} \quad h_2 = (X_1 \geq 4.5) = (X_1 - 4.5 \geq 0) \quad D_2 = \frac{1}{2} \ln\left(\frac{\frac{15}{16}}{\frac{2 \cdot 2}{16}}\right) = \ln\sqrt{\frac{2}{2}}$$

$$D_3: \begin{pmatrix} X_1 & X_2 & X_3 & X_4 & X_5 & X_6 & X_7 & X_8 & X_9 \\ \frac{1}{28} & \frac{1}{28} & \frac{1}{28} & \frac{1}{28} & \frac{1}{4} & \frac{2}{28} & \frac{1}{28} & \frac{1}{28} & \frac{1}{28} \end{pmatrix}$$

$$X_4, X_5: \frac{\frac{1}{16}}{\frac{2 \cdot 2}{16}} = \frac{1}{4} \quad h_1$$

$$X_6: \frac{\frac{1}{2}}{\frac{2 \cdot 15}{16}} = \frac{2}{7}$$

$$\text{gradient: } \frac{\frac{1}{16}}{\frac{2 \cdot 14}{16}} = \frac{1}{28}$$



$$H_T(x) = \text{sign}(\alpha_1 \cdot h_1(x) + \alpha_2 \cdot h_2(x))$$


$$H_2(x) = \text{sign}\left(\ln\sqrt{8} \cdot \text{sign}(x_1 - 2.5) + \ln\sqrt{\frac{2}{2}} \cdot \text{sign}(x_1 - 4.5)\right)$$

$\begin{matrix} // \\ 1.039 \\ \end{matrix} > \begin{matrix} // \\ 0.626 \\ \end{matrix}$

t	α_t	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
$h_1 \rightarrow$	1	$\ln\sqrt{8} = 1.039$	-	-	-	+	+	+	+	+
$h_2 \rightarrow$	2	$\ln\sqrt{\frac{2}{2}} = 0.626$	-	-	-	-	-	-	+	+
		$H_T(x_i)$	-	-	-	+	+	+	+	+

Obs. cā $H_2(x)$ clasificā gandrīz ievērojot vienību x_6 .

f)



X_1	0.5	2.5	3.5	4.5	
$D_3 (X_1 \leq 1)$	$\frac{1}{2} + \frac{3}{28} = \frac{12}{28}$	$\frac{6}{28} + \frac{1}{2} = \frac{20}{28}$	$\frac{6}{28}$	$\frac{1}{2}$	
$D_3 (X_1 \geq 1)$	$\frac{11}{28}$	$\frac{3}{28}$	$\frac{22}{28}$	$\frac{1}{2}$	

X_2	0.25	1	1.75	2.5	3.5
$D_3 (X_2 \leq 1)$	$\frac{12}{28}$	$\frac{25}{28}$	$\frac{24}{28}$	$\frac{23}{28}$	$\frac{1}{2} + \frac{1}{28} + \frac{2}{28} + \frac{2}{7} = \frac{3}{28} + \frac{2}{28} + \frac{2}{28} = \frac{18}{28}$
$D_3 (X_2 \geq 1)$	$\frac{11}{28}$	$\frac{3}{28}$	$\frac{4}{28}$	$\frac{3}{28}$	$\frac{10}{28}$


$$\varepsilon_3 = \frac{3}{28} \quad h_3 = (X_2 \geq 1) = (X_2 - 1)$$

$$d_3 = \frac{1}{2} \ln \left(\frac{\frac{25}{28}}{\frac{3}{28}} \right) = \ln \sqrt{\frac{25}{3}}$$

$$D_3(i) : \begin{cases} \frac{D_3(i)}{2 \cdot \varepsilon_3} & i \in \{X_1, X_2, X_3\} \\ \frac{D_3(1)}{2 \cdot (1 - \varepsilon_3)} & i \notin \{X_1, X_2, X_3\} \end{cases}$$

$$X_1, X_2, X_3 : \frac{1}{6} \quad X_4, X_5 : \frac{\frac{1}{2} - \frac{12 \cdot 25}{28}}{28} = \frac{2}{50} \quad X_7, X_8, X_9 : \frac{1}{50}$$

$$X_6 : \frac{\frac{1}{2} - \frac{11}{28}}{28} = \frac{4}{28}$$



	α_f	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9
$h_1 \rightarrow$	1 $\ln \sqrt{8} = 1.039$	-	-	-	+	+	+	+	+	+
$h_2 \rightarrow$	2 $\ln \sqrt{\frac{3}{2}} = 0.626$	-	-	-	-	-	-	-	+	+
$h_3 \rightarrow$	3 $\ln \sqrt{\frac{25}{3}} = 1.060$	+	+	-	+	+	+	-	+	+
	$H_T(x_i)$	-	-	-	+	+	+	-	+	+

ero. la and. este acum 0.

Dacă adă boala ar fi alături compoziție $h_3 = (x_2 - 2.5)$


x_9, x_1, x_3 ar fi fără grădini, învăță $H_3(x)$ - final ar fi fără ero. fel.

Decarele ponderile majoritare pt h_1, h_2 și x_1, x_3, x_9 să fie corect remul.


Se consideră că aplicăm algoritmul AdaBoost pe dataset-ul din figura alăturată. (Pentru ușurință exprimările la calcule, am notat pe figură indicii instanțelor de antrenament, în imediata apropiere a acestora.)

Folosim convenția noastră obișnuită de notare: simbolul \bullet desemnează instanțe pozitive, iar simbolul \circ instanțe negative.

La primele trei iterări ale algoritmului au fost selectați compasii de decizie h_1 , h_2 și h_3 (în această ordine), așa cum se indică în figurile de mai jos.



598



Obiectivul acestei probleme este să determinăm dacă la sfârșitul celor trei iterări algoritmul AdaBoost reușește să clasifice perfect toate instanțele de antrenament.

a. Calculați

- distribuțiile probabiliste corespunzătoare celor 3 iterări, adică $D_1(x_i)$, $D_2(x_i)$ și $D_3(x_i)$, pentru $i = 1, \dots, 10$;
- pentru fiecare dintre cele 3 iterări ($t = 1, 2, 3$): eroarea ponderată la antrenare (ε_t) produsă de compasul de decizie h_t , precum și ponderea (α_t) asociată ipotezei / compasului de decizie h_t .

Veți completa tabelele următoare și veți indica succint(!) modul în care ați procedat pentru a ajunge la rezultatele respective.

i	1	2	3	4	5	6	7	8	9	10
$D_1(x_i)$	1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10	1/10
$D_2(x_i)$	1/6	1/6	1/6	1/14	1/14	1/14	1/14	1/14	1/14	1/14
$D_3(x_i)$	7/66	7/66	7/66	1/22	1/22	1/6	1/6	1/22	1/6	1/22

$$\varepsilon_1 = \frac{3}{10} \quad \alpha_1 = \frac{1}{2} \ln \frac{\frac{7}{10}}{\frac{3}{10}} = \ln \sqrt{\frac{7}{3}}$$

$$D_2(x_i); \begin{cases} \frac{D_1(i)}{2 \cdot \varepsilon_1}, & i \in \{1, 2, 3\} \\ \frac{D_1(i)}{2 \cdot (1 - \varepsilon_1)}, & i \notin \{1, 2, 3\} \end{cases}$$

$$1, 2, 3: \frac{1}{10} = \frac{1}{6}$$

$$4, 5, 6, \dots, 10: \frac{1}{10} = \frac{1}{14}$$

$$\frac{2 \cdot \frac{3}{10}}{10} = \frac{7}{10}$$

$$\varepsilon_2 = \frac{3}{14} \quad \lambda_2 = \frac{1}{2} \ln \frac{\frac{11}{14}}{\frac{3}{14}} = \ln \sqrt{\frac{11}{3}}$$

$$D_3(x_i) : \begin{cases} \frac{D_2 i}{2 \cdot \varepsilon_2} & : i \in \{6, 7, 9\} \\ \frac{D_2 i}{2 \cdot (1 - \varepsilon_2)} & : i \notin \{6, 7, 9\} \end{cases}$$

$$6, 7, 9 : \frac{1}{\frac{14}{3}} = \frac{1}{6}$$

$$2 \cdot \frac{3}{14}$$

$$\frac{1}{6}$$

$$4, 5, 8, 10 : \frac{1}{\frac{14}{11}} = \frac{1}{22}$$

$$2 \cdot \frac{11}{14}$$

$$\frac{1}{22}$$

$$1, 2, 3 : \frac{1}{\frac{14}{7}} = \frac{7}{66}$$

$$2 \cdot \frac{11}{14}$$

$$\frac{7}{66}$$

$$\varepsilon_3 : \frac{3}{22} \quad \lambda_3 = \frac{1}{2} \ln \frac{\frac{19}{22}}{\frac{3}{22}} = \ln \sqrt{\frac{19}{3}}$$

t	1	2	3
ε_t	$\frac{3}{10}$	$\frac{3}{14}$	$\frac{3}{22}$
α_t	$\ln \sqrt{\frac{3}{3}}$	$\ln \sqrt{\frac{11}{3}}$	$\ln \sqrt{\frac{19}{3}}$

Atenție! Pentru a vă ușura munca, am completat noi câteva dintre elementele tabelului precedent. Bazați-vă pe valorile indicate de noi, ca să nu faceți calcule laborioase, păstrând însă rigurozitatea / corectitudinea raționamentelor.

b. Folosind ipoteza combinată obținută de algoritmul AdaBoost la finalul celei de-a treia iterării, stabiliți:


i. eroarea la antrenare produsă (pentru calcularea ei, puteți folosi tabelul de mai jos),

ii. zonele de decizie corespunzătoare acestui clasificator (veți justifica modul în care ați procedat!). Veți indica aceste zone de decizie, precum și granițele de decizie, pe primul desen din enunț.


t	α_t	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
1	$\alpha_1 = 0.923$	-	-	-	-	+	-	-	+	-	-
2	$\alpha_2 = 0.640$	+	+	+	-	+	+	+	+	+	-
3	$\alpha_3 = \dots$	+	+	+	+	-	-	-	-	-	-
	$H_3(x_i)$	+	+	+	-	+	-	-	+	=	=

$$H_3(x) = \text{sign}(\alpha_1 h_1(x) + \alpha_2 h_2(x) + \alpha_3 h_3(x))$$

err. 0 und. = 0.



τ	d_1	R_1	R_2	R_3	R_4	R_5	R_6
1	0.923	+	-	-	+	-	-
2	0.690	+	+	-	+	+	-
3	0.022	+	+	+	-	-	-
	$4f_3(R_i)$	+	+	-	+	-	-



(AdaBoost: întrebări în legătură cu aplicarea algoritmului pe un set de date din \mathbb{R}^2)

• o CMU, 200X spring, midterm, pr. 3
MIT, 2006 fall, Tommi Jaakkola, final, pr. 2


Folosind algoritmul AdaBoost, vrem să obținem un ansamblu de compași de decizie (engl., decision stumps) h_t , de forma $H(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$.

În figura alăturată sunt desenate câteva puncte (instante) etichetate în planul bidimensional, precum și primul compas de decizie care a fost ales de către algoritmul AdaBoost. Un compas de decizie oarecare produce valori binare ± 1 , ținând cont doar de un anumit *prag* (engl., the split point). Sârgeata mică din figură, care este perpendiculară pe dreapta care reprezintă compasul de decizie indică *zona de decizie* pentru care compasul de decizie va produce valoarea +1.

- a. Încercuți toate instanțe din figură pentru care ponderea / probabilitatea [atribuită de către AdaBoost] va crește ca urmare a incorporării [în ipoteza combinată H] primului compas de decizie. Justificați răspunsul în mod riguros.

b. Desenați pe aceeași figură un compas de decizie care va putea fi selectat la următoarea iterație a algoritmului AdaBoost. Veți trasa atât dreapta care reprezintă compasul de decizie cât și [o săgeată care să indice] zona sa de decizie pozitivă. Justificați în mod riguros.

c. Va fi oare coeficientul / votul α_2 , care este asociat celui de-al doilea compas de decizie mai mare decât α_1 , coeficientul [din ansamblul H] pentru primul compas de decizie? Cu alte cuvinte, vom avea oare $\alpha_2 > \alpha_1$? Justificați în mod riguros.



Precaptulare:

$\text{sign}(x \geq 0)$

$$H_3(x) = \text{Sign}(\alpha_1 \cdot h_1(x) + \alpha_2 \cdot h_2(x) \dots)$$

a) declared inst. side clas. grant \Rightarrow pt. own. it.
acts inst. clarif. grant near areas o prob. mai' more.

$$\text{Initial: } D_1(i) = \frac{1}{6} \quad , \quad i \in \{1 \dots 6\}$$

$$\varepsilon_1 = \frac{1}{6}$$

$$\left\{ \begin{array}{l} \frac{D_1(i)}{2 \cdot \varepsilon_1}, \quad i = 3 \\ \frac{D_1(i)}{2(1 - \varepsilon_1)}, \quad i \in \{ \text{neutral} \} \end{array} \right. \Rightarrow D_1(i) = \frac{1}{6}, \quad i \in \{1 \dots 6\}$$

$$\Rightarrow \frac{x}{\frac{1}{6}} = \frac{1}{2}$$

$$\Rightarrow D_1(i) = \frac{1}{i}, i \in \{1 \dots C\} \Rightarrow$$


$$\Rightarrow \frac{\frac{1}{k^2}}{\frac{5}{k^3}} = \frac{1}{10}, \quad i \in \{1 \dots 6\} / \{3\}$$

$$D_2(X) = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ \frac{1}{10} & \frac{1}{10} & \frac{1}{2} & \frac{1}{10} & \frac{1}{10} & \frac{1}{10} \end{pmatrix}$$

↳ ne oles. inst. 3 (rea invenitò)

O Oresund,

b)



$x_1 < -1$	-1	$x_1 \geq 3$	$x_1 \in (-1, 3)$	$x_1 \in [3, \infty)$	5
$\Pr(X_1 < -1)$	$\frac{3}{10}$	$\frac{1}{10}$	$\frac{6}{10}$	$\frac{1}{2}$	
$\Pr(X_1 \geq 3)$	$\frac{7}{10}$	$\frac{9}{10}$	$\frac{4}{10}$	$\frac{1}{2}$	

$x_1 < -1$	-1	$x_1 \in (-1, 1)$	$x_1 \in (1, 1.5)$	$x_1 \in (1.5, 2)$	$x_1 \in (2, 2.5)$	$x_1 \in (2.5, 3)$	3
$\Pr(X_1 < -1)$	$\frac{3}{10}$	$\frac{2}{10}$	$\frac{3}{10}$	$\frac{6}{10}$	$\frac{2}{10}$	$\frac{6}{10}$	$\frac{6}{10}$
$\Pr(X_1 \geq 3)$	$\frac{7}{10}$	$\frac{8}{10}$	$\frac{3}{10}$	$\frac{4}{10}$	$\frac{3}{10}$	$\frac{4}{10}$	$\frac{4}{10}$

$$\xi_2 = \frac{1}{10} \quad \varphi_2 = \frac{1}{2} - \xi_2 = \frac{4}{10}, \quad \alpha_2 = \frac{1}{2} \ln \left(\frac{1 - \xi_2}{\xi_2} \right) =$$

$$= \frac{1}{2} \cdot \ln \frac{\frac{9}{10}}{\frac{1}{10}} = \frac{1}{2} \cdot \ln 9$$

$h_1 = (X_1 < 3) = \text{sign}(3 - X_1)$

$$\begin{cases} \frac{D_2(i)}{2 \cdot \xi_2}, & i \in \{X_1\}, \\ \frac{D_2(i)}{2 \cdot (1 - \xi_2)}, & i \in \{\text{restal}\} \end{cases}, \quad \begin{cases} \frac{\frac{1}{10}}{2 \cdot \frac{1}{10}} = \frac{1}{2} \\ \frac{\frac{1}{10}}{2 \cdot \frac{9}{10}} = \frac{1}{18} \end{cases}$$

Gesucht
korrekt

$$D_3(X): \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ \frac{1}{18} & \frac{1}{18} & \frac{1}{18} & \frac{1}{2} & \frac{1}{18} & \frac{1}{18} \end{pmatrix}$$

$$H_2(x) = \text{sign}(\alpha_A h_A(x))$$

c)


$$\begin{aligned} \alpha_1 &= \frac{1}{2} \cdot \ln \frac{(1-\epsilon_1)}{\epsilon_1} = \frac{1}{2} \ln \frac{5}{6} = \frac{1}{2} \cdot \ln 5 \\ \alpha_2 &= \frac{1}{2} \ln 9 \\ \Rightarrow \alpha_2 &> \alpha_1 \quad \text{De zon areea.} \end{aligned}$$

63.

(Algoritmul AdaBoost: exemplu de aplicare pe date din \mathbb{R}^2 ; întrebări calitative)

• prelucrare de Liviu Ciortuz, 2021, după
MIT, 2007 fall, Tommi Jaakkola, final ex, pr. 1

Fie setul de date de antrenament din figura alăturată. Am marcat cu semnul \circ exemplele / instanțele negative ($y_i = -1$) și cu semnul \bullet instanțele pozitive ($y_i = +1$). Figura conține de asemenea ponderile normalizate (adică, probabilitățile) asociate exemplelor de antrenament, așa cum au rezultat în urma executării unui anumit număr de iterații ale algoritmului AdaBoost. În figură sunt trăsați și trei compași de decizie, $h(x; \theta_A)$, $h(x; \theta_B)$ și $h(x; \theta_C)$ sau, pe scurt, A, B și C.



a. Care dintre acești trei compași de decizie considerați că a fost folosit la *precedenta iteratie* a algoritmului AdaBoost, în așa fel încât să rezulte ponderile [asociate exemplelor] prezentate în figură? Veți răspunde indicând A, B sau C și veți justifica în mod riguros alegerea pe care ați făcut-o.

b. Pe care dintre acești trei compași de decizie considerați că-l va selecta algoritmul AdaBoost la *iterația următoare*? Veți răspunde indicând A, B sau C și veți justifica riguros, prin calcule, alegerea pe care ați făcut-o.

c. În figura dată, încercuți instanțele de antrenament (este posibil să nu fie niciuna!) pe care ansamblul (i.e., combinația liniară de compași de decizie) $H_2(x) = \text{sign}(\alpha_A h(x; \theta_A) + \alpha_C h(x; \theta_C))$, cu $\alpha_A = 0.3$ și $\alpha_C = 0.5$ nu le poate clasifica în mod corect.

c) C. → decareze număr inst. clas. greșit = $\frac{1}{2}$, conf.
prop. AdaBoost.

$$x_2 + x_3 = 6.2 + 0.3 = 0.5 = \frac{1}{2}$$

b) A: clas. greșit $x_6 \Rightarrow 0.06$

B: Clas. greșit $x_5 \Rightarrow 0,05$

C: o prob. selectat astăzi $\Rightarrow 0,5$

Avg. vo alege la urm. it pond. cea mai mică.

Urm. clas. ales rea fi B.

C.

$$H_2(x) = \text{sign}(\alpha_A h(x; \Theta_A) + \alpha_C h(x; \Theta_C)), \text{ cu } \alpha_A = 0,3 \\ \alpha_C = 0,5$$

nu avem deci în $\Rightarrow H_2(x)$ nu clasifică după
cel mai mare $\alpha \Rightarrow \alpha_C = 0,5 \Rightarrow$ deci nu nu clasifică corect

x_2, x_3 sunt B clas. tot greșit.

70.

(Concete din R reprezentabile cu ajutorul combinațiilor liniare de compoziții de decizie)

Liviu Ciortuz, 2021, pornind de la
• CMU, 2011 spring, Roni Rosenfeld, HW10, pr. 4.a

Presupunem că avem o problemă de clasificare a unor instanțe pe axa reală: fiecare instanță x_i este un număr real, iar etichetele pe care urmează să le prezică sunt binare, $y_i \in \{-1, +1\}$.

Pentru această problemă de clasificare, veți folosi *ansambluri*, adică niște combinații liniare de separatoare / ipoteze „slabe”. (Atenție! NU trebuie să folosiți algoritmul AdaBoost!) Vă readuce aminte că un astfel de *clasificator* are forma următoare:


$$\hat{y} = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right), \quad (269)$$

unde \hat{y} este eticheta prezisă, $\text{sign}(x)$ este $+1$ dacă $x > 0$ și respectiv -1 în cazul contrar, α_t este o *pondere* (număr real strict pozitiv), iar $h_t(x)$ este prediciția făcută de către ipoteza „slabă” h_t . Fiecare h_t ia una dintre următoarele forme:

$$h_t(x; s, +) = \begin{cases} -1 & \text{dacă } x < s \\ +1 & \text{dacă } x \geq s \end{cases} \quad h_t(x; s, -) = \begin{cases} +1 & \text{dacă } x < s \\ -1 & \text{dacă } x \geq s, \end{cases}$$

pentru un anumit *prag de separare* (engl., split threshold) $s \in \mathbb{R}$.

Considerăm următorul set de date, format din 5 instanțe situate pe axa reală:




a. Arătați că acest set de date (LC: sau, acest concept) este *reprezentabil* cu ajutorul unei combinații liniare care este formată din 4 ipoteze „slabe”. Așadar, vă cerem să identificați în mod explicit 4 ipoteze „slabe” h_1, \dots, h_4 , precum și ponderile lor $\alpha_1, \dots, \alpha_4$, astfel încât ipoteza combinată $\text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$ să fie *consistentă* cu datele de mai sus.

Puneți în evidență cele 4 ipoteze „slabe” h_1, \dots, h_4 pe desenul de mai sus, folosind praguri de separare s_1, \dots, s_4 precum și linii verticale, cărora le veți asocia o etichetare adecvată. Concret, veți desenă cu semnele $+/-$ la stânga și la dreapta fiecărei linii verticale — asociată unui anumit prag s_j — zonele de decizie determinate de această ipoteză „slabă”.

Observație: Înălțând cu de modul în care a fost definită funcția *sign* mai sus, *regula de predicție* (269) va trata cauzurile de „paritate” etichetând cu -1 instanțele pentru care suma ponderată (engl., weighted sum) a predicțiilor facute de ipoteze „slabe” este 0. Acest mod de tratare a cauzelor de „paritate” este [foarte] util pentru rezolvarea punctului o.

Împărtășim faptul că definiția dată aici pentru noțiunea de ipoteză „slabă” corespunde bine-cunoștințului

606



$$h_1 \Rightarrow h_1(x; n_1, -) = \begin{cases} +1 & \text{dacă } x < n_1 \\ -1 & \text{dacă } x \geq n_1 \end{cases}$$

$$h_2 \Rightarrow h_2(x; n_2, +) = \begin{cases} -1 & \text{dacă } x < n_2 \\ +1 & \text{dacă } x \geq n_2 \end{cases}$$

$$h_3 \Rightarrow h_3(x; n_3, -)$$

$$h_4 \Rightarrow h_4(x; n_4, +)$$

ob. mă. cazu de egalitate.

$$g^1 = \operatorname{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

$$g^1 = \operatorname{sign} (\alpha_1 h_1(x) + \alpha_2 h_2(x) + \alpha_3 h_3(x) + \alpha_4 h_4(x))$$

Indicație: Pentru a justifica ușor consistența ansamblului ales de dumneavoastră cu datele din figura de mai sus, vă cerem să completați un tabel similar cu cel pe care-l folosim la algoritmul AdaBoost atunci când facem calculul erorii la antrenare produse de ipoteza combinată $\operatorname{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$.

α_t	h_t	0	1	2	3	4
$\alpha_1 =$	$h_1(x_i) /$	+	-	+	+	-
$\alpha_2 =$	$h_2(x_i)$	-	-	-	+	+
$\alpha_3 =$	$h_3(x_i)$	+	+	-	-	-
$\alpha_4 =$	$h_4(x_i)$	-	+	+	+	+
	$\operatorname{sign} \left(\sum_{t=1}^4 \alpha_t h_t(x_i) \right)$	-	+	-	+	-

- b. Demonstrați că setul de date de mai sus NU este reprezentabil cu mai puțin de 4 ipoteze „slabe“.
- c. Generalizați rezultatul obținut la punctul a, referindu-vă la posibilitatea (sau, dimpotrivă, imposibilitatea) de a reprezenta — folosind combinații liniare de ipoteze „slabe“ aşa cum au fost definite mai sus — dataset-uri arbitrar [formate din instanțe situate] pe axa reală.

5)