

Ex: 26, 27, 31, 32, 35, 51

31.

(Aplicarea algoritmului Bayes Naiv:
chestiunea valorilor lipsă (engl., missing values)
în datele de antrenament)

□ • CMU, 2013 fall, A. Smola, G. Gordon, midterm practice, pr. 9

Fie setul de date de antrenament (x, y) și datele de test z :

$$\begin{aligned} x_1 &= (0, 0, 0, 1, 0, 0, 1) & y_1 &= 1 \\ x_2 &= (0, 0, 1, 1, 0, 0, 0) & y_2 &= 1 \\ x_3 &= (1, 1, 0, 0, 0, 1, 0) & y_3 &= -1 \\ x_4 &= (1, 0, 0, 0, 1, 1, 0) & y_4 &= -1 \end{aligned}$$

$$\begin{aligned} z_1 &= (1, 0, 0, 0, 0, 1, 0) \\ z_2 &= (0, 1, 1, 0, 0, 1, 1) \end{aligned}$$

Ce problemă va întâmpina clasificatorul Bayes Naiv pe aceste date?
(Indicație: Pentru ca răspunsul dumneavoastră să fie că mai bine justificat, veți estima toți parametrii necesari și veți aplica algoritmul pe cele două instanțe de test. Veți nota atributele cu A_1, A_2, \dots .)

La curs am prezentat un „remediu” standard pentru o astfel de problemă. Precizați cum se numește „tehnica” respectivă și aplicați-o pe aceste date. După aceea, veți aplica algoritmul Bayes Naiv pentru a clasifica instanțele de test z_1 și z_2 .

$$\begin{aligned} y_{\text{MAP}} &= \underset{y \in \{0, 1\}}{\operatorname{argmax}} P(u_j | y) \stackrel{\text{F.B.}}{=} \underset{y \in \{0, 1\}}{\operatorname{argmax}} \frac{P(a_i | u_j) \cdot P(u_j)}{P(a_i)} \\ &= \underset{y \in \{0, 1\}}{\operatorname{argmax}} \prod P(a_i | u_j) \cdot P(u_j) \quad \text{P.P. lini. cond.} \end{aligned}$$

$$z_1 = (1, 0, 0, 0, 0, 1, 0)$$

$$P_{y=1} = P(A_1=1|y=1) \cdot P(A_2=0|y=1) \cdots P(y=1)$$

$$z_1: P_{y=1} = \frac{0}{2} \cdot \frac{2}{2} \cdot \frac{1}{2} \cdot \frac{0}{2} \cdot \frac{2}{2} \cdot \frac{0}{2} \cdot \frac{1}{2} \cdot \frac{2}{2} = 0$$

$$z_1: P_{y=-1} = \frac{2}{2} \cdot \frac{1}{2} \cdot \frac{2}{2} \cdot \frac{2}{2} \cdot \frac{1}{2} \cdot \frac{2}{2} \cdot \frac{2}{2} \cdot \frac{2}{2} = \frac{1}{8}$$

$$z_2 = (0, 1, 1, 0, 0, 1, 1)$$

$$P_{z_2=1} = \frac{2}{2} \cdot \frac{0}{2} \cdot \frac{1}{2} \cdot \frac{0}{2} \cdot \frac{2}{2} \cdot \frac{0}{2} \cdot \frac{1}{2} = 0$$

$$P_{z_2=-1} = \frac{0}{2} = 0$$

Observează că avem probabilități care reprezintă înmulțirea cu 0 ⇒

Folosim regula „add-avee” a lui Laplace

pentru a „netezii” probabilitățile.

$$z_1 = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}$$

$$\begin{aligned} P_{y=1} &= \frac{0+1}{2+2} \cdot \frac{0+1}{4} \cdot \frac{1+1}{4} \cdot \frac{0+1}{4} \cdot \frac{2+1}{4} \cdot \frac{0+1}{4} \cdot \frac{1+1}{4} = \\ &= \frac{1}{4} \cdot \frac{1}{4} + \frac{1}{52} \cdot \frac{1}{4} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{3}{6} = \frac{1}{16} \cdot \frac{1}{8} \cdot \frac{3}{16} \cdot \frac{1}{8} = 0.001 \end{aligned}$$

$$P_{y=-1} = \frac{2+1}{2+2} \cdot \frac{2}{4} \cdot \frac{3}{4} \cdot \frac{3}{4} \cdot \frac{2}{4} \cdot \frac{3}{5} \cdot \frac{3}{4} \cdot \frac{3}{6} = 0.029$$

Prim. vormare $P_{y=-1} > P_{y=1} \Rightarrow BN$ vo clasifico z_1 in class $y=-1$

$$z_2 = (0, 1, 1, 0, 0, 1, 1)$$

$$P_{y=1} = \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{2}{5} \cdot \frac{1}{5} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{2}{5} \cdot \frac{3}{6} = 0.001$$

$$P_{y=-1} = \frac{1}{5} \cdot \frac{2}{5} \cdot \frac{1}{5} \cdot \frac{3}{5} \cdot \frac{2}{5} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{3}{6} = 0.001$$

$P_{y=1} = P_{y=-1}$, Deci BN va prezice z_2 ca fiind in $y=1$ sau

$y=-1$ cu probabilitatea $\frac{1}{2}$.

Fie D un set de exemple (date de antrenament), iar H o mulțime de ipoteze pentru (un algoritm de) învățare automată pe datele D . Precizați care este valoarea de adevăr a următoarelor afirmații:

$\operatorname{argmax}_{h \in H} P(D|h)$ este ipoteză de probabilitate maximă a posteriori, [iar]
 $\operatorname{argmax}_{h \in H} P(h|D)$ este ipoteză de verosimilitate maximă.

Fals

v MAP = $\operatorname{argmax}_{h \in H} P(D|h)$ \rightarrow fals în ceea ce:

$$\text{v}_{\text{MAP}} = \operatorname{argmax}_{h \in H} P(h|D) = \frac{P(D|h) \cdot P(h)}{P(D)}$$

În MAP suntem cunoscute datele din trecut (initial) și suntem de a observa noi date.

În ipoteza ML nu suntem nici, observăm datele direct și după trag concluzii în funcție de datele observate $\Rightarrow P(h|D)$

Deci pentru v_{MLE} = $\operatorname{argmax}_{h \in H} P(D|h)$

Deci în MLE căutăm acea ipoteză $h \in H$ care să maximizeze probabilitatele datelor D observate fără a lăsa cunoscute alte date inițiale.

Să la MAP căutăm

în fel să maximizăm $P(D|h)$ ținând cont și de prob. datelor inițiale $P(h)$ \Rightarrow $\operatorname{argmax}_{h \in H} P(D|h) \cdot P(h)$
 ("prior")

(Algoritmul Bayes Naiv:
calculul ratei medii a erorii – exemplificare)

• ◦ CMU, 2011 spring, Tom Mitchell, midterm, pr. 5.1-2

Considerăm o problemă de clasificare binară în care se folosește o variabilă $X_1 \in \{0, 1\}$ și eticheta $Y \in \{0, 1\}$. Distribuția generativă „adevărată” $P(X_1, Y) = P(Y) \cdot P(X_1|Y)$ este determinată conform tabelelor următoare:

Y	0	1
$P(Y)$	0.8	0.2

$P(X_1 Y)$	$Y = 0$	$Y = 1$
$X_1 = 0$	0.7	0.3
$X_1 = 1$	0.3	0.7

a. Presupunem că am antrenat un clasificator Bayes Naiv folosind o infinitate de date de antrenament generate conform celor două tabele de mai sus. Scrieți în tabelul următor predicțiile făcute de algoritmul Bayes Naiv pentru diferitele valori ale lui X_1 . Remarcați faptul că $\hat{Y}(X_1)$ din acest tabel este decizia [lui Bayes Naiv] cu privire la valoarea lui Y dat fiind X_1 . În coloanele care corespund probabilităților, veți scrie atât valorile concrete ale acestor probabilități, cât și modul cum au fost ele calculate (de exemplu, $0.8 \cdot 0.7 = 0.56$), iar în coloana care corespunde deciziei, veți scrie [pe fiecare linie] fie $\hat{Y} = 0$ fie $\hat{Y} = 1$.

	$P(X_1, Y = 0)$	$P(X_1, Y = 1)$	$\hat{Y}(X_1)$
$X_1 = 0$	0.56	0.06	0
$X_1 = 1$	0.24	0.14	0

408

$$\begin{aligned} P(X_1, Y=0) &\stackrel{P_C}{=} P(X_1=0 | Y=0) \cdot P(Y=0) = 0.7 \cdot 0.8 = 0.56 \\ &= P(X_1=1 | Y=0) \cdot P(Y=0) = 0.3 \cdot 0.8 = 0.24 \end{aligned}$$

$$\begin{aligned} P(X_1, Y=1) &\stackrel{P_C}{=} P(X_1=0 | Y=1) \cdot P(Y=1) = 0.3 \cdot 0.2 = 0.06 \\ &= P(X_1=1 | Y=1) \cdot P(Y=1) = 0.7 \cdot 0.2 = 0.14 \end{aligned}$$

$$\hat{y}(x_1) \stackrel{\text{MAP}}{=} \underset{y \in \{0, 1\}}{\operatorname{argmax}} P(x_1 | Y=y) \cdot P(Y=y)$$

$$\cdot \hat{y}(x_1=0, y=0) = P(X_1=0 | Y=0) \cdot P(Y=0) = P(X_1=0, Y=0) = 0.56 \quad \checkmark \Rightarrow$$

$$\cdot \hat{y}(x_1=0, y=1) = P(X_1=0 | Y=1) \cdot P(Y=1) = P(X_1=0, Y=1) = 0.06$$

$$\hat{y}(x_1) = 0$$

atât, cunoaștem direct metoda

	$P(X_1, Y = 0)$	$P(X_1, Y = 1)$	$\hat{Y}(X_1)$
$X_1 = 0$	0.56	0.06	0
$X_1 = 1$	0.24	0.14	0

{ instanțe test

b. Cât este *rata medie a erorilor* (engl., expected error rate) produsă de acest clasificator Bayes Naiv pe *instanțele de test* care sunt generate conform primelor două tabele de mai sus? Cu alte cuvinte, calculați $P(\hat{Y}(X_1) \neq Y)$ unde perechile (X_1, Y) sunt generate conform celor două tabele.

Indicație: $P(\hat{Y}(X_1) \neq Y) = P(\hat{Y}(X_1) \neq Y, X_1 = 0) + P(\hat{Y}(X_1) \neq Y, X_1 = 1)$.

$$? \quad \hat{y} = 1 - \hat{g}(x_1)$$

Pentru următoarele trei puncte ale acestui exercițiu vom considera două variabile, și anume $X_1 \in \{0, 1\}$ și $X_2 \in \{0, 1\}$, precum și eticheta $Y \in \{0, 1\}$. Y și X_1 sunt și de data aceasta generate conform primelor două tabele de mai sus, iar apoi X_2 este creat ca o *copie exactă* (adică, dupicat) după X_1 .

$$\begin{aligned} P(\hat{g}(x_1) \neq Y) &= \sum_{X_1=0}^1 P(X_1, Y \neq \hat{g}(x_1)) = P(X_1=0, Y=1 - \hat{g}(x_1)) \\ &+ P(X_1=1, Y=1 - \hat{g}(x_1=1)) = P(X_1=0, Y=1-1) + P(X_1=1, Y=1-1) = \\ &= 0.06 + 0.14 = 0.2 \end{aligned}$$

c.) Acum vom presupune că am antrenat un clasificator Bayes Naiv folosind o infinitate de *exemple de antrenament* care au fost generate în conformitate cu primele două tabele de mai sus și cu regula de duplicare. Scrieți în tabelul următor *predicțiile* făcute de către acest clasificator Bayes Naiv pentru diferitele valori ale perechii (X_1, X_2) . În privința probabilităților din tabel, puteți să scrieți doar cum anume sunt ele calculate (de exemplu, în loc de $0.8 \cdot 0.3 \cdot 0.3 = 0.072$ veți putea scrie doar $0.8 \cdot 0.3 \cdot 0.3$ pentru a economisi un pic de timp).

	$P(X_1, X_2, Y = 0)$	$P(X_1, X_2, Y = 1)$	$\hat{Y}(X_1, X_2)$
$X_1 = 0, X_2 = 0$	0.392	0.018	0
$X_1 = 0, X_2 = 1$	0.168	0.092	0
$X_1 = 1, X_2 = 0$	0.118	0.092	0
$X_1 = 1, X_2 = 1$	0.072	0.098	1

$$P(X_1, X_2, Y=0) = P(X_1=0, X_2=0 | Y=0) \cdot P(Y=0) = \text{P.P. inv. con!}$$

$$\begin{aligned} &= P(X_1=0 | Y=0) \cdot P(X_2=0 | Y=0) \cdot P(Y=0) = \\ &= 0.7 \cdot 0.7 \cdot 0.8 = 0.392 \end{aligned}$$

$$P(X_1=0, X_2=1 | Y=0) \cdot P(Y=0) =$$

$$= P(X_1=0 | Y=0) \cdot P(X_2=1 | Y=0) \cdot P(Y=0) = 0.2 \cdot 0.3 \cdot 0.8 =$$

$$= 0.168$$

$$\bullet P(X_1=1, X_2=0 | Y=0) \cdot P(Y=0) = \boxed{=} = 0.168$$

$$\bullet P(X_1=1, X_2=1 | Y=0) \cdot P(Y=0) = P(X_1=1 | Y=0) \cdot P(X_2=1 | Y=0) \cdot P(Y=0)$$

$$= 0.072$$

$$\stackrel{1}{P}(X_1, X_2, Y=1) = P(X_1=0, X_2=0 | Y=1) \cdot P(Y=1) \quad \text{P.P. ind. cond.}$$

$$= P(X_1=0 | Y=1) \cdot P(X_2=0 | Y=1) \cdot P(Y=1)$$

$$= 0.018$$

$$P(X_1=0, X_2=1 | Y=1) \cdot P(Y=1) =$$

$$= P(X_1=0 | Y=1) \cdot P(X_2=1 | Y=1) \cdot P(Y=1) = 0.052$$

$$\bullet P(X_1=1, X_2=0 | Y=1) \cdot P(Y=1) = \boxed{=} = 0.042$$

$$\bullet P(X_1=1, X_2=1 | Y=1) \cdot P(Y=1) = P(X_1=1 | Y=1) \cdot P(X_2=1 | Y=1) \cdot P(Y=1)$$

$$= 0.098$$

d) Cât este *rata medie a erorilor* pentru acest clasificator Bayes Naiv pe instanțe de test care sunt generate în conformitate cu primele două tabele de mai sus și cu regula de duplicare?

$$\sum_{X_1=0}^1 \sum_{X_2=0}^1 P(Y \neq \hat{Y}(X_1, X_2)) = P(X_1=0, X_2=0, Y=1-0) +$$

$$+ P(X_1=0, X_2=1, Y=1-0) + P(X_1=1, X_2=0, Y=1-0) +$$

$$+ P(X_1=1, X_2=1, Y=1-0)$$

$$+ P(X_1=1, X_2=1, Y=1-1) = 0.018 + 0.042 + 0.052 \\ + 0.072 = 0.09 + 0.084 = 0.174$$

e. Comparativ cu cazul precedent (adică, fără X_2), cum s-a schimbat rata medie a erorilor (adică, a crescut ori a scăzut)? În tabelul de la punctul c, ce linie este responsabilă pentru această schimbare? Cum explicați ce s-a întâmplat?

(Observăm că rata medie a erorii a scăzut pentru datele duplicate.)

Ultima linie face schimbarea, deoarece dacă ne uităm în tabelul de la a)

obs. că pentru $X_1=1$ NB prezice doar

clasa 0. Înălț odată ce am adăugat și X_2

, $X_1=1$ este împărțit în 2 clase, atât o că și 1.

, astfel având și X_2 , alăt. NB nu clasifică „nihil” mai

bine datele care conțin atrb. $X_1=1$, având o eroare medie

mai mică. $0.174 < 0.2$. În acest caz nu apără duplicarea unui atribut, deoarece nu am și alte atributuri disponibile, deoarece fiind, duplicarea ar fi neutru să facă nă conțene mai multe date neduplicate și mai multe datele duplicate, distorsionând întrebarea reală a datelor, lumen care deține în general la o rată medie a erorii mai mare.

41.

(Comparație între clasificatorul Bayes Naiv și algoritmul ID3)

□ • ○ CMU, 2010 fall, Ziv Bar-Joseph, midterm, pr. 5.b

Care dintre afirmațiile de mai jos sunt adevărate atât pentru clasificatorul Bayes Naiv cât și pentru algoritmul ID3 pentru învățarea de arbori de decizie? (Veți putea alege nu neapărat una singură dintre aceste afirmații.)

1. În cazul ambilor clasificatori se presupune că orice pereche de atribute X_i și X_j cu $i \neq j$ — văzute ca variabile aleatoare — sunt independente.
2. În cazul ambilor clasificatori se presupune că orice pereche de atribute X_i și X_j cu $i \neq j$ sunt dependente.
3. În cazul ambilor clasificatori se presupune că orice pereche de atribute sunt independente în raport cu eticheta (adică variabila care reprezintă clasa).
4. În cazul ambilor clasificatori se presupune că orice pereche de atribute sunt dependente în raport cu eticheta.

417

1. Fals, doar la NB sunt considerate independente.

ID3 caută alt. ca cîștig de inf. maxim pentru a crea arborele de decizie.

2. Fals ↑ (opusul afirmației 1)

3. Fals la BN, deși el presupune indep. pt toate atributurile, acestea sunt condiționate de etichetă.

Fals la ID3, calculul cîștigului de inf. al tuturor atr.
este în funcție de etichetă, sugerând o relație între atribut și etichetă sa.

4. Adevărat, atributurile alg NB sunt independente condiționate de etichetă, rezultând dependența între atribut și etichetă.

34.

(Algoritmul Bayes Naiv:
calculul ratei medii a erorii – exemplificare;
comparație cu regresia logistică)prelucrare de Liviu Ciortuz, după
• * CMU, 2009 fall, Carlos Guestrin, HW1, pr. 4.1.4

Considerăm o problemă de clasificare binară în care fiecare exemplu de antrenament are două atribute binare $X_1, X_2 \in \{T, F\}$ și eticheta / clasa $Y \in \{T, F\}$.

410

Presupunem că $P(Y = T) = 0.5$, iar $P(X_1 = T|Y = T) = 0.8$, $P(X_1 = F|Y = F) = 0.7$, $P(X_2 = T|Y = T) = 0.5$ și $P(X_2 = F|Y = F) = 0.9$. (Se poate observa că atributul X_1 furnizează / constituie un indiciu întrucâtva mai puternic decât atributul X_2 în ce privește determinarea clasei unei instanțe oarecare.)

În cele ce urmează vom presupune că X_1 și X_2 sunt independente în raport cu Y .

- a. Calculați probabilitățile $P(X_1 = F|Y = T)$, $P(X_1 = T|Y = F)$, $P(X_2 = F|Y = T)$ și $P(X_2 = T|Y = F)$. Asociați răspunsului dumneavoastră o justificare generală, sub forma unei formule din teoria probabilităților:

$P(\neg A|B) = \dots$, unde A și B sunt evenimente aleatoare oarecare.

Y	T	F
$P(Y)$	0.5	0.5

$$P(Y=F) = 1 - P(Y=T) \\ = 1 - 0.5 = 0.5$$

	$P(X_1 Y=T)$	$P(X_1 Y=F)$
$X_1 = T$	0.8	0.3
$X_1 = F$	0.2	0.7

	$P(X_2 Y=T)$	$P(X_2 Y=F)$
$X_2 = T$	0.5	0.1
$X_2 = F$	0.5	0.9

Restul ab. le-am obț. prin complementaritate,

u) $X_1, X_2 \rightarrow$ indep. cond

$$P(Y=F) = 1 - P(Y=T)$$

Folosim prob. totală $P(A) = P(A, B) + P(A, \bar{B}) = 1$

$$1 = P(X_1 = T | Y=T) + P(X_1 = F | Y=T) \Rightarrow P(X_1 = F | Y=T) =$$

$$= 1 - 0.8 = 0.2$$

la fel și la celelalte.

b)

Scriți regula de decizie a algoritmului Bayes Naiv pentru $X_1 = x_1$ și $X_2 = x_2$, justificând în mod succint obținerea ei.

$$\hat{y}(x_1, x_2) = \underset{y \in \{T, F\}}{\operatorname{argmax}} P(Y=y | X_1=x_1, X_2=x_2) =$$

$$= \underset{y \in \{T, F\}}{\operatorname{argmax}} P(X_1=x_1, X_2=x_2 | Y=y) P(Y=y) =$$

D.P. indep. cond.

$$= \underset{y \in \{T, F\}}{\operatorname{argmax}} P(X_1=x_1 | Y=y) \cdot P(X_2=x_2 | Y=y) \cdot P(Y=y)$$

$$P_1, Y=T : \underset{y \in \{T, F\}}{\operatorname{argmax}} P(X_1=x_1 | Y=T) \cdot P(X_2=x_2 | Y=T) \cdot P(Y=T)$$

$$P_2, Y=F : \underset{y \in \{T, F\}}{\operatorname{argmax}} P(X_1=x_1 | Y=F) \cdot P(X_2=x_2 | Y=F) \cdot P(Y=F)$$

În funcție de param. x_1, x_2 , nu vom calcula P_1 și P_2 și vom alege maximul dintre acestea.

c. Calculați rata medie a erorii produse de algoritm Bayes Naiv, atunci când se folosesc ambele attribute, X_1 și X_2 . (Veți da în prealabil definiția ratei medii a erorii.) Este oare această rată mai bună decât în cazul în care se folosește un singur atribut (X_1 sau X_2)? De ce?

$$\text{Def: } E_P \left[\sum_{Y_{NB}(X_1, X_2) \neq Y} 1 \right]$$

Rata medie a erorii ne spune cat de pe怨t clasifico alg. datele.

$$= \sum_{X_1, X_2, Y} \frac{1}{P(X_1, X_2, Y)} \cdot P(Y \neq Y_{NB}(X_1, X_2))$$

X_1	X_2	Y	$P(X_1 Y) \cdot P(X_2 Y) \cdot P(Y)$	$Y_{NB}(X_1, X_2)$
T	T	T	$0.8 \cdot 0.5 \cdot 0.5 = 0.2$	T
T	T	F	$0.3 \cdot 0.1 \cdot 0.5 = 0.015$	T
T	F	T	$0.8 \cdot 0.5 = 0.4$	T
T	F	F	$0.3 \cdot 0.9 = 0.27$	T
F	T	T	$0.2 \cdot 0.3 = 0.06$	T
F	T	F	$0.2 \cdot 0.1 = 0.02$	T
F	F	T	$0.2 \cdot 0.5 = 0.1$	F
F	F	F	$0.2 \cdot 0.9 = 0.18$	F

$$\text{Calc: } \sum_{X_1=T}^1 \sum_{X_2=T}^1 P(\tilde{Y}(X_1, X_2) \neq Y) = P(X_1=T, X_2=T, Y=1 - \tilde{Y}(X_1, X_2))$$

$$+ P(X_1=F, X_2=T, Y=1 - \tilde{Y}(X_1, X_2)) + P(X_1=T, X_2=F, Y=1 - \tilde{Y}(X_1, X_2)) +$$

$$+ P(X_1=F, X_2=F, Y=1 - \tilde{Y}(X_1, X_2)) = \underline{0.015} + \underline{0.135} + \underline{0.035} + \underline{0.05} = \\ = 0.185 + 0.09 = 0.235$$

Da, această rețea este mai bună, deoarece are multe date, iar acest aspect face ca algoritmul NB să clasifice mai bine.

d)

d. Să presupunem acum că se crează un nou atribut, X_3 , care este o copie exactă a lui X_2 . Așadar, pentru fiecare exemplu de antrenament, atributul X_2 și X_3 au aceeași valoare, $X_2 = X_3$. Răspundeți la următoarele întrebări:

- Sunt X_2 și X_3 independente condițional în raport cu Y ?
- Cât este rata medie a erorii pentru Bayes Naiv acum? (Atenție! Distribuția „adevărată” a datelor nu s-a modificat.)
- Explicați ce se întâmplă cu algoritmul Bayes Naiv. Oare regresia logistică are aceeași problemă? Explicați de ce.

Dacă X_3 este copia lui X_2 , atunci atributul în mod clar nu este dependent de el, X_3 fiind totușt de X_2 depinde de valoarea sale, și toate valoările din X_2 corespund și cele din X_3 , ceea ce nu reprezintă o independentă.

Dacă în noi adăugăm date noi, rata medie a erorii probabil va crește, deoarece X_3 fiind copie a lui X_2 algoritmul va calca probabil cu nimic deoarece X_2 decât X_3 , ceea ce va rezulta că mai probabil va clasifica greșită o altă, ceea ce duce la creșterea ratei medii a erorii.

In Regresia Logistică nu există astfel de probleme, deoarece numărul alt. dupăcare se ajustează astfel încât să evite supraaproximarea importantă a atributelor dupăcare.

		$P(Y)$	
		$Y=T$	$Y=F$
		0.5	0.5
$X_1=T$	$P(X_1 Y=T)$	0.8	
	$P(X_1 Y=F)$	0.2	
$X_1=F$	$P(X_2 Y=T)$	0.5	
	$P(X_2 Y=F)$	0.5	
$X_1=T$	$P(Y_1 Y=F)$	0.3	
	$P(Y_1 Y=T)$	0.7	
$X_1=F$	$P(Y_2 Y=F)$	0.1	
	$P(Y_2 Y=T)$	0.9	

X_3	X_1	X_2	Y	$P(X_1, X_2, X_3, Y)$	$P_{NB}(X_1, X_2, X_3, Y) = P(X_1 Y) \cdot P(X_2 Y) \cdot P(X_3 Y) \cdot P(Y)$	$y_{NB}(X_1, X_2, X_3, Y)$
T	T	T	T	0	$0.2 \cdot 0.5 \cdot 0.5 = 0.2 \cdot 0.5 = 0.1$	T
T	T	T	F	0	$0.3 \cdot 0.1 \cdot 0.5 = 0.015 \cdot 0.1 = 0.0015$	T
T	T	F	T	0.2	$0.2 \cdot 0.5 = 0.2 \cdot 0.5 = 0.1$	T
T	T	F	F	0.135	$0.3 \cdot 0.9 = 0.3 \cdot 0.1 = 0.035$	T
T	F	T	T	0	$0.2 \cdot 0.5 = 0.2 \cdot 0.5 = 0.025$	T
T	F	T	F	0	$0.2 \cdot 0.1 = 0.2 \cdot 0.1 = 0.0025$	T
T	F	F	T	0.05	$0.2 \cdot 0.5 = 0.05 \cdot 0.5 = 0.025$	F
T	F	F	F	0.315	$0.3 \cdot 0.9 = 0.315 \cdot 0.1 = 0.0315$	F
F	T	T	T	0.2	$0.2 \cdot 0.5 \cdot 0.5 = 0.2 \cdot 0.5 = 0.1$	T
F	T	T	F	0.015	$0.3 \cdot 0.1 \cdot 0.5 = 0.015 \cdot 0.9 = 0.0135$	T
F	T	F	T	0	$0.2 \cdot 0.5 = 0.2 \cdot 0.5 = 0.1$	F
F	T	F	F	0	$0.3 \cdot 0.9 = 0.3 \cdot 0.1 = 0.315$	F
F	F	T	T	0.05	$0.2 \cdot 0.5 = 0.05 \cdot 0.5 = 0.025$	F
F	F	T	F	0.035	$0.2 \cdot 0.1 = 0.035 \cdot 0.9 = 0.0315$	F
F	F	F	T	0	$0.2 \cdot 0.5 = 0.05 \cdot 0.5 = 0.025$	F
F	F	F	F	0	$0.3 \cdot 0.9 = 0.315 \cdot 0.9 = 0.2835$	F

număr
erori

[număr dependent, număr total, calc. este învalid?]
num. 0.?

[distribuția valoare de NB care să își asume
adăug. ca fiind independent. (în cazul acestuia X_2 și X_3 sunt
dependent, deci distribuția este greșită)]

$$= E_P [1_{\{y_{NB}(X_1, X_2, X_3) \neq y\}}]$$

$$= \sum_{X_1, X_2, X_3, Y} \frac{1}{\{g(X_1, X_2, X_3) \neq y\}} \cdot P(X_1, X_2, X_3, Y)$$

Așa că să calculăm dacă X_3 ar fi fost independent de X_2 .]

$$= P(X_1 = T, X_2 = T, X_3 = T, Y = 1 - g(X_1, X_2, X_3)) + P(X_1 = T, X_2 = F, X_3 = T, Y = 1 - g(X_1, X_2, X_3)) +$$

$$P(X_1 = F, X_2 = T, X_3 = T, Y = 1 - g(X_1, X_2, X_3)) + P(X_1 = F, X_2 = F, X_3 = T, Y = 1 - g(X_1, X_2, X_3)) +$$

$$P(X_1 = F, X_2 = T, X_3 = F, Y = 1 - g(X_1, X_2, X_3)) + P(X_1 = F, X_2 = F, X_3 = F, Y = 1 - g(X_1, X_2, X_3)) =$$

$$= 0.0015 + 0.0135 + 0.0035 + 0.025 + 0.0135 + 0.1 + 0.025 =$$

$$= \underline{0.005} + \underline{\underline{0.027}} + \underline{\underline{0.05}} + \underline{\underline{0.125}} = 0.13 + 0.077 = \\ = 0.207$$

Rata eroare se face pe dim. reală, P, nu pe P_{NB} . \Rightarrow

$$E_P[\mathbb{1}_{\{g(x_1, x_2, x_3) \neq y\}}] = 0.05 + 0.015 + 0.05 + 0.135 = 0.115 + 0.135 = \\ = 0.250$$

Se observă cum rata este mai mare

$0.250 > 0.235$, de unde rezultă că duplicarea atributelor pentru clasificarea NB duc la o rată de eroare mai mare.

✓ 27.

(Algoritmii Bayes Naiv și Bayes Optimal; aplicare; numărul minimal de parametri de estimat)

• Liviu Ciortuz, 2017, pornind de la setul de date din Machine Learning, Tom Mitchell, 1997, ch. Decision Trees, page 59

Considerăm următorul set de date de antrenament, în care variabila de ieșire este EnjoyTennis:

Day	Outlook	Temperature	Humidity	Wind	EnjoyTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

a. Determinați decizia luată de către algoritmul Bayes Naiv pentru instanța de test

$X = \langle \text{Outlook} = \text{sunny}, \text{Temp} = \text{cool}, \text{Humidity} = \text{high}, \text{Wind} = \text{strong} \rangle$, precum și probabilitatea cu care este luată această decizie.

b. Care este numărul *minim* de parametri pe care trebuie să-l estimeze algoritmul Bayes Naiv pe aceste date [pentru a face apoi predicții pe un set oarecare de instanțe de test]? Dar în cazul clasificatorului Bayes Optimal?

c. Implementați algoritmul Bayes Naiv, iar apoi cu ajutorul acestui implementare calculați eroarea la antrenare și eroarea la CVLOO pe acest set de date.

a)

$$y(x) = \underset{e \in \{\text{No}, \text{Yes}\}}{\operatorname{argmax}} P(E=e | O=s, T=c, H=h, W=n) =$$

$$= \underset{e}{\operatorname{argmax}} P(E=e | O=s, T=c, H=h, W=n) \cdot P(E=e) =$$

$$P(O=s, T=c, H=h, W=n) =$$

$$= \underset{e}{\operatorname{argmax}} P(E=e | O=s, T=c, H=h, W=n) \cdot P(E=e) = NB$$

$$P_1: E = \text{No } \Rightarrow P(O=s, T=c, H=h, W=s | E=n) \cdot P(E=n) =$$

N. p. ini. const

$$P(O=s | E=n) \cdot P(T=c | E=n) \cdot P(H=h | E=n) \cdot$$

$$\begin{aligned} MLE \\ = \frac{1}{5} \cdot \frac{2}{5} \cdot \frac{4}{5} \cdot \frac{3}{5} \cdot \frac{8}{14} &= 0.0511 \quad \text{Observationstabul, MLE, } \gamma \end{aligned}$$

$$P_2: E = \text{Yes}: P(O=s | E=y) \cdot P(T=c | E=y) \cdot P(H=h | E=y) \cdot P(W=s | E=y) \cdot P(E=y) = \frac{2}{3} \cdot \frac{5}{9} \cdot \frac{5}{9} \cdot \frac{3}{9} \cdot \frac{9}{14} = 0.0052$$

Deci, $P_1 > P_2$, aleg. NB vo prezice val. $X = (\dots)$ Enjoy
Termis = no.

b) Mr. minim de param., de estimat pentru NB?
Dar pentru $\hat{\beta}$?

Pentru NB vom avea un nr. liniar de param de estimat. $2d+1$.

Pentru VB vom avea un nr. exponential.

$$2^{d+1} - 1.$$

$$P(E = \text{Yes}) \Rightarrow P(E=n) = 1 - P(E=y)$$

$$P(W=s | E=y) \Rightarrow P(W=w | E=y) = 1 - P(W=s | E=y)$$

$$P(W=s | E=n) \Rightarrow P(W=w | E=n) = 1 - P(W=s | E=n)$$

$$P(H=n | E=y) \Rightarrow P(H=h | E=y) = 1 - P(H=n | E=y)$$

$$P(H=m | E=n) \Rightarrow P(H=h | E=n) = 1 - P(H=m | E=n)$$

$$\left. \begin{array}{l} P(T=c | E=y) \\ P(T=m | E=y) \end{array} \right\} \Rightarrow P(T=h | E=y) = 1 - P(T=c | E=y) - P(T=m | E=y)$$

$$\left. \begin{array}{l} P(T=c | E=m) \\ P(T=m | E=m) \end{array} \right\} = P(T=h | E=y) - P(T=c | E=m) - P(T=m | E=m)$$

$$\left. \begin{array}{l} P(O=s | E=y) \\ P(O=n | E=y) \end{array} \right\} = P(O=o | E=y) = 1 - P(O=n | E=y) - P(O=r | E=y)$$

$$\left. \begin{array}{l} P(O=s | E=m) \\ P(O=n | E=m) \end{array} \right\} = P(O=o | E=m) = 1 - P(O=n | E=m) - P(O=r | E=m)$$

→ nr. de valori ale alt. d.
→ $2^{cl(m-1)} + 1$ (dacă conținutul este binar)

Pentru NB vom avea nevoie minimă de 13 parcurg. pentru acest estimare.

În ceea ce urmărem parcurg.

Pentru datele de înșiruire care nu sunt liniare =>

$$2 \sum_{i=1}^d K_i - 1,$$

\uparrow
 y , binar

d - nr. de atribută

K_i -> nr. de valori pe care le poate avea fiecare atribut d .

$$2 \cdot (3 \cdot 3) \cdot 2 \cdot 2 - 1 = 2 \cdot 9 \cdot 4 - 1 = 72 - 1 = 71.$$

Pentru \hat{y} vom avea nevoie minimă de 71 parcurg. pentru acest estimare.

Vom arăta

$$P(O=s, T=c, H=r, W=d, y=y) = 3 \cdot 3 \cdot 2 \cdot 2 \cdot 2 - 1 = 71.$$

c) Așa căcăt că termo optională doar că ne alt set de date.
(MNIST)