

Ex: 33

33.

(Algoritmul Bayes Naiv:
calculul ratei medii a erorilor)

■ ● CMU, 2010 fall, Aarti Singh, HW1, pr. 4.2

Considerăm următoarea problemă de clasificare:

Fie variabila aleatoare $Y: Hike \in \{T, F\}$ care denotă faptul că Alice și Bob merg sau nu în drumeție în funcție de condițiile vremii: $X_1: Sunny \in \{T, F\}$ și $X_2: Windy \in \{T, F\}$.

Se presupune că au fost estimări următorii parametri:

$$\begin{aligned} P(Hike) &= 0.5 \\ P(Sunny | Hike) &= 0.8, \quad P(Sunny | \neg Hike) = 0.7 \\ P(Windy | Hike) &= 0.4, \quad P(Windy | \neg Hike) = 0.5 \end{aligned}$$

De asemenea, se consideră că este satisfăcută presupoziția de independentă condițională a algoritmului Bayes Naiv.

409

a. Care este probabilitatea (comună) ca Alice și Bob să meargă în drumeție atunci când vremea este însorită și bate vântul, adică

$$P(Sunny = T, Windy = T, Hike = T) = ?$$

Care este decizia luată de algoritm Bayes Naiv în acest caz?

$$\overbrace{P(Hike)}^{0.5} \quad \overbrace{0.5}^{\text{Sunny}} \quad \overbrace{0.5}^{\text{Windy}}$$

	$P(S H)$	$P(S \neg H)$
$Sunny = T$	0.8	0.7
$Sunny = F$	0.2	0.3

	$P(W H)$	$P(W \neg H)$
$Windy = T$	0.4	0.5
$Windy = F$	0.6	0.5

$$g_{MNP} = \underset{Y \in \{T, F\}}{\operatorname{argmax}} P(H=Y | S=T, W=T)$$

$$= \underset{Y \in \{T, F\}}{\operatorname{argmax}} \frac{P(S=T, W=T | H=Y) H=Y}{(P(S=T, W=T, H=Y))} =$$

constantă

$$y_{NP} = \underset{Y \in \{T, F\}}{\operatorname{argmax}} P(S=T, W=T | H=Y)$$

$$P_0 P(S=T, W=T, H=T) = P(S=T | H=T) \cdot P(W=T | H=T) \cdot P(H=T) = \\ = 0.8 \cdot 0.6 \cdot 0.5 = 0.480 \cdot 0.4 = 0.16.$$

! Care este prob. cu care va lua decizia?

$$\frac{P_0}{P_0 + P_1}$$

$$\frac{0.16}{0.16 + 0.125} = \frac{0.16}{0.335} = 0.477612$$

b. Completați tabelul următor:

X_1	X_2	Y	$P(X_1, X_2, Y)$	$P_{NB}(Y X_1, X_2)$	decizia algoritmului Bayes Naiv
F	F	F	0.075	0.555556	F
F	F	T	0.060	0.444444	T
F	T	F	0.075	0.652174	F
F	T	T	0.040	0.347826	F
T	F	F	0.125	0.421686	T
T	F	T	0.240	0.578313	T
T	T	F	0.175	1 - 0.477612 = 0.522388	F
T	T	T	0.16	0.423612	F

Observație: Calculele de la punctul a corespund ultimei linii din tabelul de mai sus.

$$P(X_1=T | Y=T) \cdot P(X_2=F | Y=T) \cdot P(Y=T) = 0.8 \cdot 0.6 \cdot 0.5 = 0.240$$

$$P(X_1=T | Y=F) \cdot P(X_2=F | Y=F) \cdot P(Y=F) = 0.7 \cdot 0.5 \cdot 0.5 = 0.175$$

$$P(X_1=F | Y=T) \cdot P(X_2=T | Y=T) \cdot P(Y=T) = 0.2 \cdot 0.4 \cdot 0.5 = 0.040$$

$$P(X_1=F | Y=F) \cdot P(X_2=T | Y=F) \cdot P(Y=F) = 0.3 \cdot 0.5 \cdot 0.5 = 0.075$$

$$P(X_1=F | Y=T) \cdot P(X_2=F | Y=T) \cdot P(Y=T) = 0.2 \cdot 0.6 \cdot 0.5 = 0.060$$

$$P(X_1=F | Y=F) \cdot P(X_2=F | Y=F) \cdot P(Y=F) = 0.3 \cdot 0.5 \cdot 0.5 = 0.025$$

$$P_{NB}(Y=T | X_1=T, X_2=F) = \frac{0.140}{0.140 + 0.175} = 0.57142857$$

:

c)

c. Care este rata medie a erorilor (engl., expected error rate) produse de algoritmul Bayes Naiv? Vă reamintim că această (rată) medie este definită ca fiind suma probabilităților $P(X_1, X_2, Y)$ pentru acele (triplete de) valori ale variabilelor X_1, X_2, Y pentru care decizia luată de algoritmul Bayes Naiv diferă de valoarea variabilei Y .

În cele ce urmează se presupune că se obțin mai multe informații despre vreme. Se introduce o nouă trăsătură $X_3: Rainy \in \{T, F\}$. Se presupune că în fiecare zi vremea poate fi fie *Rainy* fie *Sunny*, dar nu și *Rainy* și *Sunny*. Similar, se presupune că vremea nu poate fi într-o zi $\neg Rainy$ și $\neg Sunny$.

$$\text{err} : \stackrel{\text{def}}{=} E_p [1 \{ Y_{NB} (x_1, x_2) \neq Y \}]$$

$$= 0.160 + 0.175 + 0.050 + 0.660 = 0.435$$

d. În noile condiții, presupozitia de independență condițională rămâne oare adevărată? Justificați.

e. Calculați $P(Sunny = T, Windy = T, Rainy = F, Hike = T)$.

d) Supozitia este încălcată, deoarece primul factor corespunde

Sunny, alături *Rainy* și invers $\neg Sunny$ și $\neg Rainy$ nu sunt independenți condițional, iar BN le presupune independență.

e)

$$P(S=T, W=T, R=F, H=T) = \underbrace{P(\neg R | S, W, H)}_{\text{Concl. invers}} \cdot P(H | S, W) = \\ = P(S, W | H) \cdot P(H) = \frac{P(S | H) \cdot P(W | H) \cdot P(H)}{P(S | H) \cdot P(W | H) \cdot P(H)} = 0.16$$

f. Care este rata medie a erorilor produse de clasificatorul Bayes Naiv când se folosesc toate cele 3 atribute de intrare?

tributes? Does the performance of Naive Bayes improve by adding more attributes? Rainy? Explain why.

Solution:

X_1	X_2	X_3	Y	$P(X_1, X_2, X_3, Y)$	$P_{NB}(X_1, X_2, X_3, Y) = P(X_3 Y) \cdot P(X_1 Y) \cdot P(X_2 Y) \cdot P(Y)$	$Y_{NB}(X_1, X_2, X_3)$	$P_{NB}(Y X_1, X_2, X_3)$
				$P(X_1 Y) \cdot P(X_2 Y) \cdot P(Y)$	$Y_{NB}(X_1, X_2, X_3)$	$P_{NB}(Y X_1, X_2, X_3)$	
F	F	F	F	0	$0.075 \cdot 0.7 = 0.0525$	F	0.522388
F	F	F	T	0	$0.060 \cdot 0.8 = 0.0480$	F	0.477612
F	F	T	F	0.075	$0.075 \cdot 0.3 = 0.0225$	F	0.652174
F	F	T	T	0.060	$0.060 \cdot 0.2 = 0.0120$	F	0.347826
F	T	F	F	0	$0.075 \cdot 0.7 = 0.0525$	F	0.621302
F	T	F	T	0	$0.040 \cdot 0.8 = 0.0320$	F	0.378698
F	T	T	F	0.075	$0.075 \cdot 0.3 = 0.0225$	F	0.737705
F	T	T	T	0.040	$0.040 \cdot 0.2 = 0.0080$	F	0.262295
T	F	F	F	0.175	$0.175 \cdot 0.7 = 0.1225$	T	0.389507
T	F	F	T	0.240	$0.240 \cdot 0.8 = 0.1920$	T	0.610493
T	F	T	F	0	$0.175 \cdot 0.3 = 0.0525$	F	0.522388
T	F	T	T	0	$0.240 \cdot 0.2 = 0.0480$	F	0.477612
T	T	F	F	0.175	$0.175 \cdot 0.7 = 0.1225$	T	0.489022
T	T	F	T	0.160	$0.160 \cdot 0.8 = 0.1280$	T	0.510978
T	T	T	F	0	$0.175 \cdot 0.3 = 0.0525$	F	0.621302
T	T	T	T	0	$0.160 \cdot 0.2 = 0.0320$	F	0.378698

$$\text{Error} = \frac{0 + 0.175 + 0 + 0.175 + 0.040 + 0 + 0.060}{8} = 0.45$$

9) $0.45 > 0.435$, performanța a scăzut, deoarece aceea

o dependență între atributele Rainy și Sunny, însă BN le presupune independență, lucru care este greșit.

40.

(Algoritmul Bayes Naiv: comparație cu alți clasificatori)

prelucrare de L. Ciortuz, după

* CMU, 2004 fall, T. Mitchell, Z. Bar-Joseph, midterm, pr. 6.b

Considerăm un clasificator Bayes Naiv care lucrează pe un set de date descrise de atributele de intrare A și B și atributul de ieșire Y . (Exemplu: $Y = A \text{ XOR } B$). A și B sunt variabile aleatoare independente între ele.

a. Este posibil ca, în situația aceasta, vreun alt clasificator — de exemplu, ID3, regresia logistică (eventual kernel-izată) sau SVM — să lucreze mai bine decât clasificatorul Bayes Naiv?

b. Care este motivul?

- a) Da este posibil
- b) Funcția XOR crează o relație între A și B care este non-lineară și dependență. În cazul XOR, valoarea lui Y nu poate fi determinată decât dacă ne cunosc atributele A și B . \Rightarrow BN face presupunerile că sunt independenți și este greșit

\Rightarrow De aceea BN nu va performa foarte bine.

regresie logistica Kernel-izat, SVM și ID3, vor performa mult mai bine, deoarece acest algoritm poate gestiona relația non-lineară mai bine decât o face BN.

FUNDAMENTE

Probleme propuse

0.2.4 Estimarea parametrilor unor distribuții probabiliste

123.

(Distribuția Bernoulli: câteva chestiuni de bază; estimarea parametrului)

□ • ○ CMU, 2018 spring, Nina Balcan, HW0, pr. A.3.1-4

Considerăm setul de date $S = \{1, 1, 0, 1, 0\}$, obținut prin aruncarea unei monede X de cinci ori, unde 0 indică faptul că la aruncarea monedei a fost obținută față cu banul, iar 1 semnifică faptul că la aruncarea monedei a fost obținută față cu stema.

a. Calculați $\bar{x} = \frac{1}{|S|} \sum_{x_i \in S} x_i$, media empirică (sau, media la eșantionare; engl., the sample mean) pentru acest set de date.

b. Calculați $\sigma^2 = \frac{1}{|S|} \sum_{x_i \in S} (x_i - \bar{x})^2$, varianța empirică (sau, varianța la eșantionare; engl., the sample variance) pentru acest set de date.

c. Calculați probabilitatea de a „observa“ / obține aceste date, presupunând că ele au fost generate prin aruncarea unei monede perfecte, adică având distribuția de probabilitate $P(X=1) = 0.5$ și $P(X=0) = 0.5$.

d. Remarcați faptul că probabilitatea [generării] acestui set de date ar fi putut fi mai mare dacă valoarea lui $P(X=1)$ n-ar fi fost 0.5, ci alta. Care este valoarea care maximizează probabilitatea [generării] setului S ? Justificați riguros.

a)

$$\bar{X} = \frac{1}{|S|} \sum_{x_i \in S} x_i = \frac{1}{5} \cdot (1+1+0+1+0) = \frac{3}{5}$$

b)

$$\begin{aligned} \sigma^2 &= \frac{1}{|S|} \sum_{x_i \in S} (x_i - \bar{X})^2 = \frac{1}{5} \left(\left(1 - \frac{3}{5}\right)^2 + \left(1 - \frac{3}{5}\right)^2 + \left(0 - \frac{3}{5}\right)^2 + \left(1 - \frac{3}{5}\right)^2 + \left(0 - \frac{3}{5}\right)^2 \right) \\ &= \frac{1}{5} \left(\frac{4}{25} + \frac{4}{25} + \frac{9}{25} + \frac{4}{25} + \frac{9}{25} \right) = \\ &= \frac{1}{5} \cdot \frac{36}{25} = \frac{6}{25} \end{aligned}$$

c)

$$\begin{aligned} P(S) &= P(x_1=1) \cdot P(x_2=1) \cdot P(x_3=0) \cdot P(x_4=1) \cdot P(x_5=0) = \\ &= 0.5^5 = 0.03125 \end{aligned}$$

d)

7) Descrieți estimarea verosimilității Maxime.

Definim parametrul pe care vrem să-l calculăm: $p = P(X=1)$

prob. ză piele steme.

iar prob. ză piele ban = $1-p$.

$$\begin{aligned}
 P(S|p) &= P(X=1, X=1, X=0, X=1, X=0 | X=1) = \text{int. cond} \\
 &= P(X=1 | X=1)^3 \cdot P(X=0 | X=1)^2 = \\
 &= p^3 \cdot (1-p)^2 =
 \end{aligned}$$

Să luăm log. exponentiată în pct. de $p =$ $L(p) = p^3 \cdot (1-p)^2$

• folosim fct. logaritmică nl $L(p) = \ln L(p) = \ln p^3 + \ln(1-p)^2 =$

$$\ln L(p) = 3 \ln p + 2 \ln(1-p)$$

• derivăm nl. o cflă max. $\Rightarrow \frac{dL}{dp} = \frac{d(3 \ln p + 2 \ln(1-p))}{dp} =$

$$= \frac{3}{p} - \frac{2}{(1-p)} \cdot (-1) = \frac{3}{p} + \frac{2}{(1-p)}$$



• după rezolvare derivata cu 0 nl. a găsit punctul maxim. \Rightarrow

$$= \frac{3}{p} + \frac{2}{(1-p)} = 0 \quad / \cdot p(1-p) \Rightarrow 3(1-p) + 2p = 0 \Rightarrow 3 - 3p - 2p = 0 \Rightarrow$$

$$\Rightarrow -5p = -3 \Rightarrow p = \frac{3}{5} \Rightarrow P(X=1) = \frac{3}{5} \quad \text{—> maximum nl rezul probabilității}$$

de date S. [la cum și în următoarea derivate] $L''(p) = -\frac{3}{p^2} - \frac{2}{(1-p)^2} < 0, \forall p \in (0, 1)$
 \Rightarrow concavă

$$L''(\frac{3}{5}) = \dots < 0$$

ad. rez. MLE.

de obicei nu întotdeauna nu este concavă.

125.

(Distribuția Bernoulli:
estimarea parametrului (MLE și MAP),
într-un caz particular)

CMU, 2011 fall, T. Mitchell, A. Singh, midterm exam, pr. 2

În acest exercițiu veți estima probabilitatea ca la aruncarea unei monede să apară față steme (engl., head), făcând estimări în sensul verosimilității maxime (MLE) și, respectiv, în sensul probabilității maxime a posteriori (MAP).

Presupunem că dispunem de o monedă pentru care probabilitatea de apariție a feței cu stema este $p = 0.5$, adică este o monedă perfectă (engl., fair coin). Totuși, am dori să-i calculăm un estimator, $\hat{\theta}$. În mod obisnuit, un astfel de estimator — pentru o distribuție de tip Bernoulli — se calculează presupunând că el poate lua orice valoare din intervalul $[0, 1]$ (vedeți problema 43.c sau problema 124.a). Aici, în schimb, vom impune ca $\hat{\theta}$ să ia valori într-o mulțime finită, și anume $\{0.3, 0.6\}$.

a. Presupunem că am aruncat moneda de 3 ori și am obținut de 2 ori banul și o dată stema. Calculați estimarea de verosimilitate maximă $\hat{\theta}_{MLE}$ a lui p în raport cu setul de valori posibile, $\{0.3, 0.6\}$.²⁴³

$$a) n = P(X=1) = 0.5$$

\hookrightarrow rea fără stema
 decernare repetitivă experimentală de 3 ori $\Rightarrow S = \{0, 0, 1\}$, $P \in \{0.3, 0.6\}$

$$L(\theta) = P(\text{Date} | \theta) = P(X=0, X=0, X=1 | \theta) =$$

$$= P(X=0 | \theta) \cdot P(X=0 | \theta) \cdot P(X=1 | \theta) =$$

$$= 3 \cdot \theta \cdot (1-\theta)^2$$

X luciu pe rând $\theta \in \{0.3, 0.6\} \Rightarrow \theta = 0.3 \Rightarrow 3 \cdot \left(\frac{3}{10}\right) \cdot \left(1 - \frac{3}{10}\right)^2 = 3 \cdot \frac{3}{10} \cdot \left(\frac{7}{10}\right)^2 = 0.1573$

re inv. $\left(\frac{3}{10}\right)^2 \cdot \left(1 - \frac{3}{10}\right) \dots$
 deci, $\theta = 0.6 \Rightarrow 3 \cdot \frac{6}{10} \cdot \left(1 - \frac{6}{10}\right)^2 = 3 \cdot 0.6 \cdot 0.096 = 0.288$

estimarea de probabilitate maximă a lui p este $n = 0.3$.

b. Presupunem că folosim următoarea distribuție de probabilitate a priori pentru valorile parametrului p :

$$P(p=0.3) = 0.3 \text{ și } P(p=0.6) = 0.7.$$

Presupunem din nou că am aruncat moneda de 3 ori și am obținut de 2 ori banul și o dată stema. Calculați estimarea de probabilitate maximă a posteriori $\hat{\theta}_{MAP}$ a lui p în raport cu mulțimea de valori posibile, $\{0.3, 0.6\}$, folosind această distribuție a priori.

$$P(D|\theta) P(\theta)$$

$$S = \{0, 0, 1\} \quad n \in \{0.3, 0.6\}$$

$$L(\hat{\theta}_{MAP}) = 3 \cdot P(\text{Date}|n) \cdot \underbrace{P(n)}_{\text{d.c.}} = 3 \cdot P(X=0, X=0, X=1 | n) \cdot P(n) =$$

$$= 3 \cdot P(X=0 | n) \cdot P(X=0 | n) \cdot P(X=1 | n) \cdot P(n)$$

$$= 3 \cdot P(X=0 | n) \cdot P(X=0 | n) \cdot P(X=1 | n) \cdot P(n) =$$

$$= 3 \cdot n \cdot (1-n)^2 \cdot P(n)$$

$$\text{st. } n = 0.3 \Rightarrow 3 \cdot \left(\frac{3}{10}\right)^2 \cdot \left(\frac{7}{10}\right) \cdot \frac{3}{10} = \frac{27 \cdot 49}{1000} = 0.1323$$

$$\mu = 0.6 \Rightarrow 3 \cdot \left(\frac{6}{10}\right)^2 \cdot \left(\frac{4}{10}\right) \cdot \frac{7}{10} = \frac{18 \cdot 16 \cdot 7}{100 \cdot 100} = 0.2016$$

estimarea MAP va fi 3 pt. $p=0.6$.

d. Presupunem din nou că aruncăm moneda de un număr de ori care tinde la infinit. Calculați estimarea de probabilitate maximă a posteriori $\hat{\theta}_{MAP}$ a lui p în raport cu mulțimea de valori posibile, $\{0.3, 0.6\}$, folosind distribuția de probabilitate a priori care a fost definită la punctul b.

monedă. $P(X=1)$.

ne aruncăm moneda de n ori, unde $n \rightarrow \infty$

$$\hat{\theta}_{MAP} = n \cdot P(\text{date} | \theta) \cdot P(\theta) = n \cdot P(X=1, X=0, \dots, X=n) \cdot P(n) =$$

atât când $n \rightarrow \infty$, atunci estimarea mai mare va fi cea ce are priorul
mai mare $\Rightarrow \hat{\theta}_{MAP} = 0.6$

126.

(Estimare în sens MLE pentru distribuția Bernoulli și distribuția binomială: exemplificare)

□ • CMU, 2018 spring, Nina Balcan, HW2, pr. 2

Presupunem că „observăm“ valorile a n variabile aleatoare i.i.d. X_1, \dots, X_n , toate urmând o [aceeași] distribuție Bernoulli de parametru θ .²⁴⁴ Cu alte cuvinte, știm că pentru orice $i = 1, \dots, n$, au loc egalitățile

$$P(X_i = 1) = \theta \text{ și } P(X_i = 0) = 1 - \theta.$$

Scopul nostru este să estimăm [în sensul verosimilității maxime, MLE] valoarea parametrului θ , pornind de la aceste valori „observate“, X_1, \dots, X_n .

a. Scrieți formula funcției de log-verosimilitate, $\ell(\theta)$. Această funcție va depinde de variabilele aleatoare X_1, \dots, X_n și de parametrul θ . Aduceți expresia acestei funcții la cea mai simplă formă posibilă. (Așadar, nu vă limitați la a scrie doar definiția funcției de log-verosimilitate.)

Determinați o formulă analitică (engl., a closed form expression) pentru estimarea de verosimilitate maximă, $\hat{\theta}_{MLE}$.²⁴⁵

Folosiți formula pe care ați determinat-o mai sus pentru a calcula $\hat{\theta}_{MLE}$ pentru următoarele 10 „observații“:

$$X = (0, 1, 1, 1, 1, 0, 1, 0, 1, 1).$$

d)

$$\begin{aligned} L(\theta) &= P(X_1=x_1, X_2=x_2, \dots, X_n=x_n | \theta) = \\ &= \prod_{i=1}^n P(X_i=x_i | \theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} \quad \rightarrow \text{fct. de verosimilitate} \\ l(\theta) &= \ln L(\theta) = \ln \left(\prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} \right) = \sum_{i=1}^n (x_i \ln \theta + (1-x_i) \ln (1-\theta)) \end{aligned}$$

Pe notam cu K nr. total rez $\sum_{i=1}^n x_i = K$

$$\begin{aligned} - \text{nr. de rez. 1} &= \sum_{i=1}^n y_i = k \\ - \text{nr. de rez. 0} &= \sum_{i=1}^n (1-x_i) = (n-K) \quad | = \quad k \ln \theta + (n-k) \ln (1-\theta) \end{aligned}$$

Formula analitică pt. estimarea verosimilității maxime:

- derivată
- egalăm cu 0

derivată

$$\textcircled{a} \quad \frac{\partial l(\theta)}{\partial \theta} = \frac{k}{n} + \frac{(n-k) \cdot 1}{(1-\theta)} (-1) = \frac{k}{n} - \frac{n-k}{(1-\theta)}$$

egalăm cu 0:

$$\textcircled{b} \quad \frac{k}{\theta} - \frac{n-k}{(1-\theta)} = 0 \Rightarrow \frac{k}{\theta} = \frac{n-k}{(1-\theta)}$$

$$\Rightarrow k - k\theta = n\theta - k\theta \Rightarrow k = n\theta \Rightarrow \theta = \frac{k}{n}$$

$$\Rightarrow \theta = \frac{7}{10} = 0.7$$